RELATÓRIO TÉCNICO

INTEGRANTES: Gustavo Lanna

EMPRESA ESCOLHIDA: E-commerce (HQMania)

PRODUTO ESCOLHIDO: Avaliações de Quadrinhos

1 – INTRODUÇÃO

O constante crescimento do comércio eletrônico gera diariamente um volume massivo de avaliações e comentários de clientes sobre produtos. A análise manual desses feedbacks é inviável, tornando essencial o desenvolvimento de sistemas automatizados baseados em Processamento de Linguagem Natural (PLN) para identificar se o sentimento expressado é positivo ou negativo.

Este relatório apresenta o desenvolvimento e a análise de um sistema em Python capaz de classificar automaticamente 100 avaliações de clientes utilizando técnicas de similaridade textual. O objetivo principal é comparar a eficácia da Similaridade de Jaccard e da Distância de Levenshtein na categorização dos textos em relação a duas avaliações de referência (positiva e negativa).

2 - REFERENCIAL TEÓRICO

- Pré-processamento de Texto: Etapa fundamental em PLN que limpa e padroniza os dados textuais antes da aplicação das métricas. Envolve a conversão de caracteres para minúsculas, remoção de pontuações, eliminação de espaços extras e tokenização (divisão do texto em palavras).

- Similaridade de Jaccard: Métrica estatística que mede a similaridade entre conjuntos. Calculada pela razão entre o tamanho da intersecção e o tamanho da união dos conjuntos de palavras:

$$J(A,B) = \frac{|A \cap B|}{|A \cup B|}$$

Desconsidera a ordem e a repetição das palavras.

- Distância de Levenshtein: Métrica que calcula a quantidade mínima de operações de edição (inserção, remoção ou substituição de caracteres) necessárias para transformar uma sequência de caracteres em outra. Trata-se de uma métrica de distância onde valores menores indicam maior similaridade.

3 – METODOLOGIA

A atividade foi desenvolvida em linguagem Python seguindo os seguintes passos:

1. Leitura dos Dados: Leitura do arquivo Excel (avaliacoes.xlsx) contendo 100 avaliações de clientes utilizando a biblioteca pandas.
2. Definição das Referências: Definição da avaliação de referência positiva (*"O produto possui excelente qualidade, chegou rapidamente..."*) e negativa (*"O produto possui péssima qualidade, apresentou problemas..."*).
3. Pré-processamento: Aplicação da padronização em minúsculas, remoção de pontuações e tokenização para todas as frases.
4. Cálculo das Métricas:
    - Cálculo do coeficiente de Jaccard entre o conjunto de palavras de cada avaliação e o conjunto das referências positiva e negativa.
    - Cálculo da distância de Levenshtein no nível de caracteres da string limpa em relação às referências.
5. Classificação e Exportação:

- *Jaccard:* Classificado como POSITIVA se Jaccard Positivo > Jaccard Negativo; caso contrário, NEGATIVA.
- *Levenshtein:* Classificado como POSITIVA se Levenshtein Positivo < Levenshtein Negativo; caso contrário, NEGATIVA.
- Geração de tabela final e exportação dos resultados para o arquivo resultado_avaliacoes.xlsx.

4 – RESULTADOS

Abaixo estão dispostas as respostas quantitativas e qualitativas referentes ao processamento dos dados:

- 1. Avaliações classificadas como positivas por Jaccard: 29 avaliações.
- 2. Avaliações classificadas como negativas por Jaccard: 71 avaliações.
- 3. Avaliações classificadas como positivas por Levenshtein: 43 avaliações.
- 4. Avaliações classificadas como negativas por Levenshtein: 57 avaliações.
- 5. Quantidade de avaliações com a mesma classificação nas duas métricas: 66 avaliações (66% de concordância).
- 6. Quantidade de avaliações com classificações diferentes: 34 avaliações (34% de divergência).
- 7. Por que Jaccard e Levenshtein podem produzir resultados diferentes para uma mesma avaliação?

  As métricas analisam dimensões textuais distintas. A Similaridade de Jaccard foca estritamente no conjunto de palavras únicas (tokens), sem se importar com a ordem gramatical ou o tamanho total da frase. Já a Distância de Levenshtein opera no nível de caracteres e estrutura sequencial (string completa). Portanto, duas frases com vocabulário similar podem ter comprimentos ou sequências de caracteres muito distintas, resultando em classificações divergentes.

- 8. Qual das duas métricas apresentou maior sensibilidade às diferenças entre os textos?

  A Distância de Levenshtein demonstrou maior sensibilidade às variações estruturais e de escrita dos textos. Por contabilizar individualmente cada alteração de caractere e ser fortemente influenciada pelo tamanho da string, ela capturou proximidades de escrita que o conjunto de palavras

de Jaccard desconsiderou, alterando a classificação em 34 das 100 avaliações.

5 - CONCLUSÃO

O desenvolvimento do projeto permitiu comprovar a viabilidade e a eficiência da utilização de técnicas de similaridade textual para a automação da análise de sentimentos em avaliações de e-commerce.

A comparação entre as abordagens evidenciou que a Similaridade de Jaccard é ideal para análises focadas no vocabulário chave (tokens), enquanto a Distância de Levenshtein é mais detalhista em relação à estrutura sequencial dos caracteres. A taxa de concordância de 66% entre as métricas demonstra a solidez do pré-processamento e da classificação, fornecendo uma base automatizada confiável para auxiliar a tomada de decisão da empresa.